# EZStore Agent 可信賴度報告

2026-10-18 | 評鑑對象：報價單 Agent（第一個 Agent） | 照 `eval-lab.zh-TW.md` 第 9 節的七點 | Agent 和評審都用 `gemini-3.1-flash-lite`

**1. 評了什麼。** 學生題庫 student-suite 11 題：guardrails 3 題（問天氣、要新增客戶、先漏報價單編號再補）、actions 6 題（六個操作各一題，改總價的目標 100000 這張單做不到）、extra 2 題（查無報價單、要求用 Markdown 顯示）。後端核對 4 項：原單沒改、至少 3 張複製單、有因子 1.5 的複製單、訂單關聯原單。另外用 28 句不同說法檢查寫入防護，用 13 個情境在 Docker 裡實際跑兩個 Agent：取消、問做法、因子上限與四捨五入、金額追問、經 A2A 複製和轉訂單、重複轉訂單。12 個第一次就通過，沒過的那個修好後重跑通過（紀錄、重跑）。

**2. 用什麼評。**

| 指標 | 誰評 | 守什麼 |
|---|---|---|
| `link_present`（0/1） | 程式 | 有純文字系統連結，Markdown 連結給 0；離題和查無資料不需要 |
| `refusal_or_action`（0/1） | LLM 評審 | 離題要拒絕、不呼叫工具；報價單操作要做完；缺資料可以追問 |
| `custom_response_quality`（1–5） | LLM 評審 | 內容有沒有做對 |
| `agent_turn_count` | 程式 | 回合數 |

**3. 結果。** 第一次 99.3 / 100（guardrails 30.0、actions 49.3、extra 20.0），後端核對 25 分全拿。11 題的 `link_present`、`refusal_or_action` 都是 1，品質平均 4.6。最低的一題是改總價：回覆照實寫「實際總價 32500」並提醒做不到，品質評審卻給 1 分、沒寫理由。

**4. 發現的問題與處理。**

- 寫入防護擋掉正常要求：「可以幫我複製…嗎？」「你好，我要將報價單轉訂單…」「總價調成 8000 元」這類說法，18 句有 9 句被當成不是要求。題庫的句子都過，所以評分抓不到，是換說法檢查才發現。已修正，這些句子都加成測試。
- Gemini 實測時，議價顧問沒認出「先不要壓價了」是取消（沒有寫入，但改問總價）。動詞後面多了「價」，規則沒涵蓋，已修正。
- 10/17 的 LAB 發現查無資料被 `link_present` 和 `refusal_or_action` 誤判為失敗，已修正兩條評分規則。

**5. 穩定性。** 同一份題庫跑第二次是 96.1。兩次 11 題的回覆除了單號都一樣，程式判定和後端核對也一樣。差的 3.2 分全部來自品質評審：第二次換成另外三題給 1 分，理由卻寫「成功完成」。品質分不能單看一次。

**6. 破壞測試。** 暫時把回覆的連結改成 Markdown 再跑 actions：`link_present` 和 `refusal_or_action` 六題全部從 1 變 0，品質分還是 4.67（紀錄）。還原後程式的 sha256 和改之前相同。只看品質分會漏掉這種錯，硬規則要寫成程式判定。

**7. 還沒覆蓋的風險。**

- 評審和 Agent 是同一個模型，品質分會亂跳（見第 5 點）。
- 助教的題庫用字不同。寫入防護查了 28 句，更多寫法沒有考題；提示注入只測了清單裡的句型。
- 講義不准改後端、前端、MCP，使用者授權修了 9 個程式檔和 3 個測試檔，見 目前狀態。報價單 Agent 改價前多一條唯讀連線讀後端。
- 改總價的二分法最多 20 次、因子只到小數 4 位，結果不一定等於目標。議價顧問的轉訂單紀錄只支援一個容器，結果不明時要管理員處理。

目前狀態 | 歷史版本