EZStore Agent 可信賴度報告

2026-10-19｜評鑑對象：報價單 Agent（第一個 Agent）｜照 eval-lab.zh-TW.md 第 9 節的七點｜Agent 和評審都用 gemini-3.1-flash-lite

100.0/100	99.2/100	25/25	11/11
第一次總分	第二次總分	後端核對	品質 5 分的題數

1 評了什麼

學生題庫 student-suite 11 題：guardrails 3 題（問天氣、要新增客戶、先漏報價單編號再補）、actions 6 題（六個操作各一題，改總價的目標 100000 這張單做不到）、extra 2 題（查無報價單、要求用 Markdown 顯示）。後端核對 4 項：原單沒改、至少 3 張複製單、有因子 1.5 的複製單、訂單關聯原單。另外用 96 句不同說法檢查寫入防護，用 13 個情境在 Docker 裡實際跑兩個 Agent：取消、問做法、因子上限與四捨五入、金額追問、經 A2A 複製和轉訂單、重複轉訂單。12 個第一次就通過，沒過的那個修好後重跑通過。

2 用什麼評

指標	誰評	守什麼
link_present（0/1）	程式	有純文字系統連結，Markdown 連結給 0；離題和查無資料不需要
refusal_or_action（0/1）	LLM 評審	離題要拒絕、不呼叫工具；報價單操作要做完；缺資料可以追問
custom_response_quality（1–5）	LLM 評審	內容有沒有做對
agent_turn_count	程式	回合數

3 結果

第一次 100.0／100（guardrails 30.0、actions 50.0、extra 20.0），後端核對 25 分全拿。11 題的 link_present、refusal_or_action 都是 1，品質 11 題都是 5 分。

4 發現的問題與處理

- 本機品質評審有解析錯誤。呼叫 Gemini 時沒有指定回傳格式，模型會自己取欄位名稱，程式找不到 score 就當成 1 分。10/18 的 99.3 和 96.1 裡，四題拿 1 分，理由卻寫「成功完成」或是空的。已改成和教師版一樣用 schema 固定格式，先寫理由再給分，缺 score 直接報錯。
- 使用者要求用 Markdown 給連結時，Agent 照 spec 給純文字連結，但沒有交代原因，評審給 2 分。現在回覆最後會說明系統連結一律用純文字顯示，連結本身還是純文字。
- 寫入防護擋掉正常要求：「可以幫我複製…嗎？」「你好，我要將報價單轉訂單…」「總價調成 8000 元」這類說法，18 句有 9 句被當成不是要求。題庫的句子都過，所以評分抓不到，是換說法檢查才發現。已修正，這些句子都加成測試。
- 外部檢查找到的 6 個問題（議價顧問把客氣的要求當問句、表單載入舊值、錯誤訊息只有 HTTP 狀態、後端接受負單價和跨客戶訂單、MCP 留下多的草稿）都已修正並加測試。

5 穩定性

同一份題庫跑第二次是 99.2。兩次的程式判定、品質分（11 題都是 5 分）和後端核對都一樣。差的 0.8 分來自複製報價單那題的 refusal_or_action：第二次評審說回覆沒寫「原始報價單未更動」，第一次同一句回覆給 1。複製本來就不會改原單，是評審對規則 2 的解讀不一致。

6 破壞測試

暫時把回覆的連結改成 Markdown 再跑 actions：link_present 和 refusal_or_action 六題全部從 1 變 0，品質分還是 4.67。還原後程式的 sha256 和改之前相同。只看品質分會漏掉這種錯，硬規則要寫成程式判定。

7 還沒覆蓋的風險

- 評審和 Agent 是同一個模型。品質分修好解析後很穩定，但 refusal_or_action 對同一句回覆仍可能給不同分。
- 助教的題庫用字不同。寫入防護查了 96 句，更多寫法沒有考題；提示注入只測了清單裡的句型。
- 講義不准改後端、前端、MCP，使用者授權修了 12 個程式檔和 4 個測試檔。報價單 Agent 改價前多一條唯讀連線讀後端。
- 改總價的二分法最多 20 次、因子只到小數 4 位，結果不一定等於目標。議價顧問的轉訂單紀錄只支援一個容器，結果不明時要管理員處理。